2026. 10. 25 · 최종 과제 보고서

Day Zero
토론으로 인성을 본다

AI 동료 3명과의 턴 기반 음성 토론에서 인성을 관찰하는 채용 서비스

서비스 구성	web · api · MCP 3 · worker
음성	Azure F0 TTS · STT
측정 기준	2026-10-25 · gpt-4o-mini
아키텍처 원본	docs/share/architecture.html

목차

1 **서비스 개요** 3

1.1 핵심 요약 3

1.2 문제 정의와 서비스 구성 4

2 **시스템 아키텍처** 5

2.1 전체 구성 5

2.2 구성 요소와 배포 6

3 **에이전트 설계** 7

3.1 에이전트 구성 7

3.2 음성 토론 한 턴 8

3.3 단계 전환과 칸 확정 9

4 **MCP 설계와 접근 경계** 10

5 **평가 설계(BARS)** 11

6 **품질 관리와 검증 결과** 12

6.1 하네스와 검증 계층 12

6.2 검증 결과 13

7 **주요 기능과 구현 결과** 14

7.1 음성 회의 화면 14

7.2 자료 열람과 AI 어시스턴트 15

7.3 디브리핑과 관리자 리포트 16

8 **한계와 개선 방향** 17

1.1 핵심 요약

60분 음성 토론 한 번으로 인성 5요소의 행동 근거를 남긴다.

지원자가 AI 동료 3명과 턴 기반 음성으로 키워드 · 문제 상황 · 해결책을 정하고
기획안을 내면, 평가 에이전트가 근거를 들어 수준을 제안하고 담당자가 최종 평가합니다.

세션
60분
단계별 10 · 18 · 18 · 14분, 데모 15분

발언 한 번
60초
받아 적은 글 그대로 제출, 차례 유지 20초

AI 동료
3명
강한결 · 윤하람 · 서지안, 모든 세션 고정

인성 요소
5요소
설득 · 경청 · 배려 · 수용 · 정직

BARS 척도
19차원
차원마다 수준 1~5 + 근거

MCP 서버
3개
debate · rag · assessment, 도구 16개

표 1-1 **핵심 설계 결정**

결정	내용
결정은 코드, 말투는 LLM	입장 · 합의 · 카드 시각 · 시간 초과 · 차례는 규칙이 정하고, LLM은 의도 분류 · 화자 보조 · 발언 문장만 만든다
말한 그대로가 근거	받아 적은 글은 지원자가 보거나 고치지 않고 그대로 제출된다. 서버도 다른 글은 거부한다
재생이 끝나야 내 차례	동료 발언은 검증된 최종 문장만 음성으로 바꿔 순서대로 재생하고, 실제 재생 종료를 확인한 뒤 지원자 차례를 연다
시간과 쓰기의 주인은 api	시간 초과 채우기 · 강제 차례 · 업무 데이터 쓰기는 api만 한다. MCP와 워커는 `/internal`을 부른다
평가 정보 차단	토론 동료는 assessment-mcp에 닿지 않는다(허용 목록 + 토큰)

핵심 메시지

(1)
장면은 같고 말투만 다르다
같은 채용 건의 지원자는 같은 페르소나 · 카드 6장 · 시간 · 음성 규칙을 겪습니다.

(2)
AI 동료는 평가 기준을 모른다
토론에 참여하는 페르소나는 척도와 관찰 기록에 접근할 수 없습니다.

(3)
판단은 근거로, 확정은 사람이
근거 없는 수준은 내지 않고, 담당자가 차원 단위로 조정합니다. 총점은 없습니다.

1.2 문제 정의와 서비스 구성

말로 묻는 검사 대신 회의 속 행동을 근거로 쓴다.

기업은 인성과 협업 태도를 중요하게 보지만 측정은 자기 보고와 짧은 면접에 기댑니다. Day Zero는 그 태도가 드러나는 회의 상황을 음성 토론으로 만들고 발언을 근거로 남깁니다.

표 1–2 **문제와 근거**

문제	근거
원하는 것과 재는 것이 다르다	면접 유형은 질의응답이 94.1%, 실무 수행은 10.7%
자기 보고는 꾸밀 수 있다	거짓말이 가장 잘 드러나는 전형으로 실무면접 65.5%, 인적성 검사 2.4%
잘못된 채용은 비싸다	인사담당자 60.9%가 최근 1년 안에 신입 조기 퇴사를 경험
지원자는 이유를 모른다	취업준비생 51.5%가 최종 면접 불합격 통보조차 받지 못함

표 1–3 **60분 세션 흐름**

단계	시간	장면	관찰 요소
키워드	10분	후보 4개(물 · 불 · 나무 · 바람) 중 하나로 합의. 다른 키워드를 민 동료가 반론	설득
문제 상황	18분	두 동료가 지원자 안과 다른 안을 지지하고 고집형 동료가 강하게 밈	수용 · 경청
해결책	18분	소극형 동료가 말을 거두고, 비판형 동료가 지원자 안의 약점을 자료로 짚음	배려 · 설득
기획안	14분	지원자가 6칸 템플릿을 혼자 써서 제출. 새 음성 차례는 없고 어시스턴트만 도움. 아이디어 기여 칸을 실제 최초 제안자와 대조	정직

기업이 받는 것

토론 기록(받아 적은 발언 · 동료 원문) · 제출 기획안과 함께, 차원별 수준과 근거, 확신도가 담긴 리포트. 합격 · 불합격 · 순위는 만들지 않습니다.

지원자가 받는 것

말이 아닌 행동으로 보여 줄 기회와 디브리핑. 어떤 장면이 설계되어 있었는지 설명하고 이의 제기 경로를 줍니다.

2.1 전체 구성

브라우저는 api만 만나고, 음성은 api가 Azure와 주고받는다.

번호는 지원자 발언 한 번과 동료 응답 재생, 세션 종료 뒤 리포트까지의 처리 순서입니다. 빨간 화살표는 아래 계층이 api의 `/internal`을 부르는 예외 경로입니다.

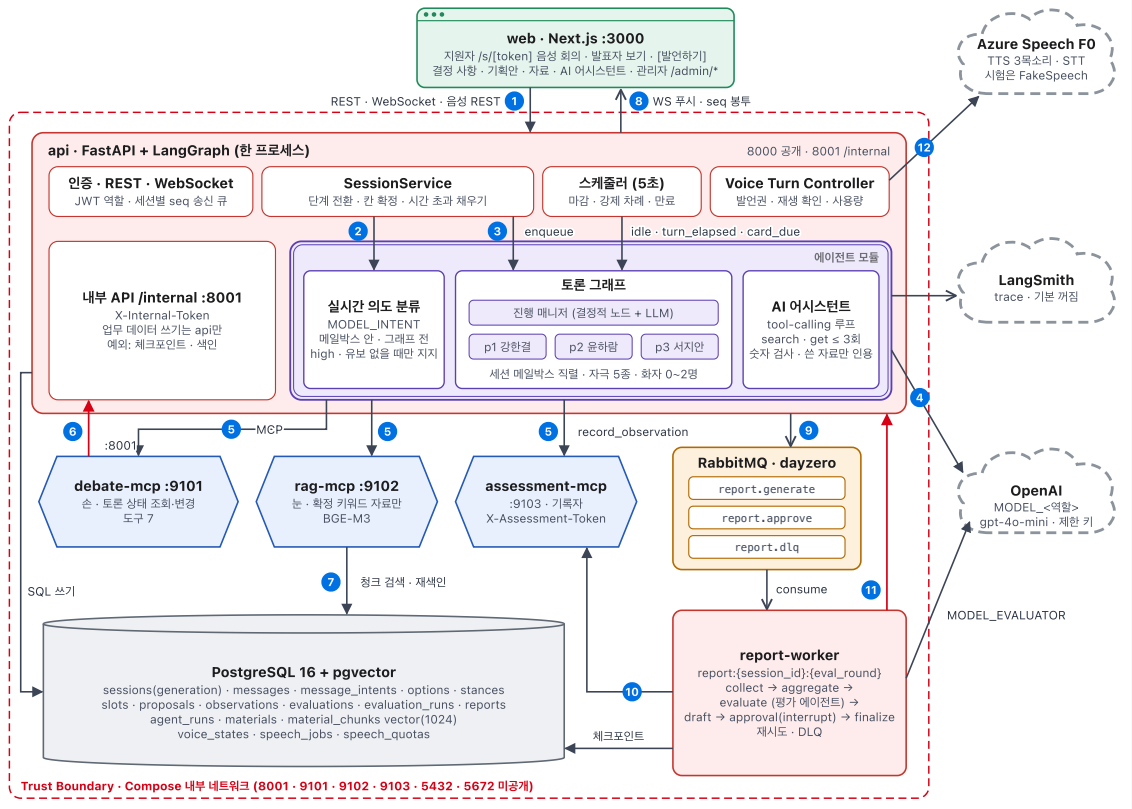


그림 2–1 전체 구성도. 공개 포트는 web과 api뿐이고, MCP · 워커 · DB · 큐는 Compose 내부 네트워크에 있습니다. 음성 공급자는 테스트 프로필에서 FakeSpeech로 바뀝니다.

표 2–1 번호별 처리 흐름

번호	구간	처리 내용	프로토콜
1	web → api	[발언하기] 발언권 요청, 녹음 WAV 업로드, 받아 적은 글 그대로 message.send(client_msg_id = utterance_id)	REST, WebSocket
2·3	api → 의도 분류 · 그래프	같은 글인지 검증 · 저장 · generation +1 → 메일박스가 자극을 꺼내 분류하고 지지를 반영한 뒤 그래프 실행	프로세스 내부
4·5	에이전트 → OpenAI · MCP	역할별 모델 호출, 허용된 MCP 도구 호출	HTTPS, MCP HTTP
6·7	MCP → api · pgvector	변경 · 자료 원문은 `/internal` 경유, 청크 검색만 pgvector 직접	HTTP :8001, SQL
8	api → web	칸 확정 · 단계 전환을 seq 봉투로 푸시, 음성 상태는 `/voice` 750ms 조회	WebSocket, REST
9~11	api → 큐 → 워커	종료 뒤 리포트 작업 발행, 평가 저장, 리포트 저장. thread는 `report:{session_id}:{eval_round}`	AMQP, MCP, HTTP
12	api → Azure	검증된 최종 발언만 TTS, 녹음은 STT. 호출 전 사용량 원장 차감	HTTPS

2.2 구성 요소와 배포

서비스는 8개이고, 업무 데이터는 api만 쓴다.

구성 요소마다 맡은 일과 하지 않는 일을 정해 경계를 지킵니다. 에이전트와 음성 턴 컨트롤러는 api 프로세스 안의 모듈이지만 계층은 라우터 → SessionService → AgentRunner → 그래프 → MCP 어댑터로 나눕니다.

표 2-2 **구성 요소별 역할과 금지 사항**

구성 요소	역할	하지 않는 일
web	지원자 음성 회의 화면과 관리자 리포트 화면	권한 판단, MCP 직접 호출
api	인증 · REST · WebSocket, 단계 전환과 칸 확정, 시간 초과 채우기, 스케줄러, 업무 데이터 쓰기	—
음성 턴 컨트롤러	발언권 · 녹음 · 받아 적기 · 재생 확인 상태 (api 안). TTS · STT는 교체 가능한 인터페이스	토론 규칙 판단, 유료 음성 호출
에이전트 모듈	의도 분류 · 토론 그래프 · 어시스턴트(api 안)	DB 직접 쓰기
debate-mcp	토론 상태 조회 · 발언 게시 · 안 제안 · 입장 · 칸 채우기	토론 규칙 판단(api가 최종)
rag-mcp	확정 키워드 청크 검색 · 재색인(직접), 원문 조회(`/internal` 경유)	에이전트에 변경 도구 노출
assessment-mcp	카드 관찰 기록 · 평가 입력 조회 · 평가 저장	페르소나의 접근 허용
report-worker	리포트 그래프와 평가 에이전트, 재시도와 DLQ. 직접 쓰기는 체크포인트만	수준 · 근거 고쳐 쓰기

표 2-3 **Compose 서비스와 실행 프로필**

서비스	포트	기다리는 의존 · 비고
web	`3000` 공개	api
api	`8000` 공개 · `8001`	postgres · rabbitmq · MCP 3개. 8001은 내부 전용
MCP 3개	`9101` · `9102` · `9103`	FastMCP. rag-mcp는 BGE-M3, assessment-mcp는 토큰 검사
report-worker	없음	postgres · rabbitmq · api · assessment-mcp. heartbeat 30초
postgres · rabbitmq	`5432` · `5672`	PostgreSQL 16 + pgvector, 관리 UI는 127.0.0.1에만

실행 프로필

음성과 LLM을 프로필로 고정합니다. `test-text` · `test-voice`는 가짜 LLM, `eval-text` · `eval-voice`는 실제 LLM(제한 키), 음성 프로필의 공급자는 FakeSpeech입니다. `dev-real` · `deploy`만 Azure F0를 쓰며 F0가 확인되지 않으면 시작을 막습니다. 실제 API를 부르는 명령은 `ALLOW_API=1`을 명시해야 돕니다.

3.1 에이전트 구성

참여자로 보이는 AI는 셋, 뒤에서 일하는 에이전트는 넷이다.

세션 중에는 api 안에서 의도 분류 · 토론 그래프 · 어시스턴트가 돌고, 세션이 끝나면 report-worker의 평가 에이전트가 돕니다.

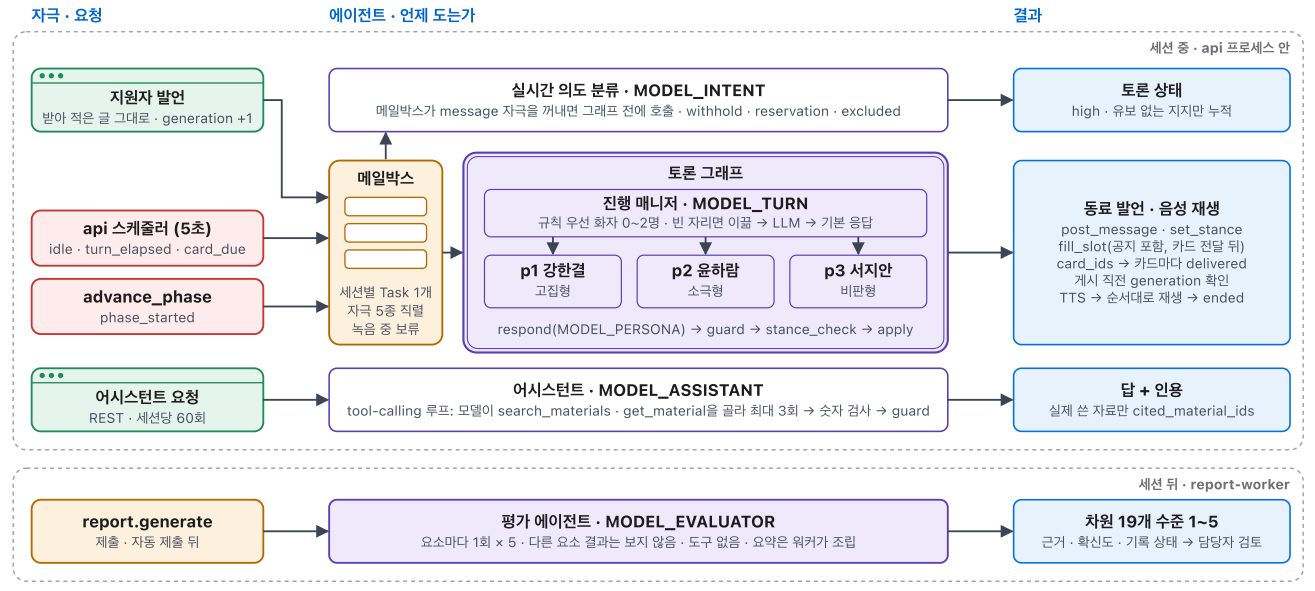


그림 3–1 에이전트 구성도. 자극 5종은 메일박스로 모여 토론 그래프가 하나씩 처리하고, 게시된 발언은 음성으로 재생됩니다. 평가는 세션 뒤 큐 작업으로 분리됩니다.

표 3–1 에이전트별 역할

에이전트	하는 일	도구
진행 매니저	자극마다 화자 0~2명을 규칙으로 정하고, 규칙으로 정해지지 않은 지원자 발언에만 LLM을 씀	결정적 노드가 debate-mcp 전부 · record_observation
페르소나 × 3	성향 · 고정 입장 · 자리 기억(자기 발언 최대 3개)으로 1~2문장(약 120자) 발언	get_transcript · get_draft · rag 2, 응답당 3회. DebateState는 컨텍스트로
의도 분류	지원자 발언을 제안 · 동의 · 반대 · 질문 · 기타와 대상 안, 지명 대상으로 분류	없음, 10초 넘으면 기타
어시스턴트	지원자 요청에 자료를 스스로 골라 인용과 함께 답함	rag 2, 최대 3회
평가 에이전트	요소마다 1회 호출로 차원별 수준 · 근거 · 확신도 판단	없음(워커가 입력 주입)

표 3–2 세션 페르소나

자리	이름 · 유형	토론에서 하는 일
p1	**강한결 · 고집형**	자기 안을 반복해 밀고 반대에 바로 재반박. 확정 전에는 입장을 바꾸지 않음
p2	**윤하람 · 소극형**	스스로 주장하지 않음. 이름이 불리면 자료 근거로 자기 안을 말함
p3	**서지안 · 비판형**	모이는 안의 약점을 짚음. 지원자 안 제안 · 동의 2회면 옮길 수 있음. 설득 카드 · 침묵 초대 담당

3.2 음성 토론 한 턴

동료 발언이 끝까지 재생된 뒤에야 지원자 차례가 열린다.

음성 턴 컨트롤러는 토론 그래프 바깥에서 6개 상태를 관리합니다. 그래프 · 의도 분류 · guard · 합의 규칙은 텍스트 경로와 같고, 음성은 그 앞뒤에 녹음 · 받아 적기와 재생 확인을 붙입니다.

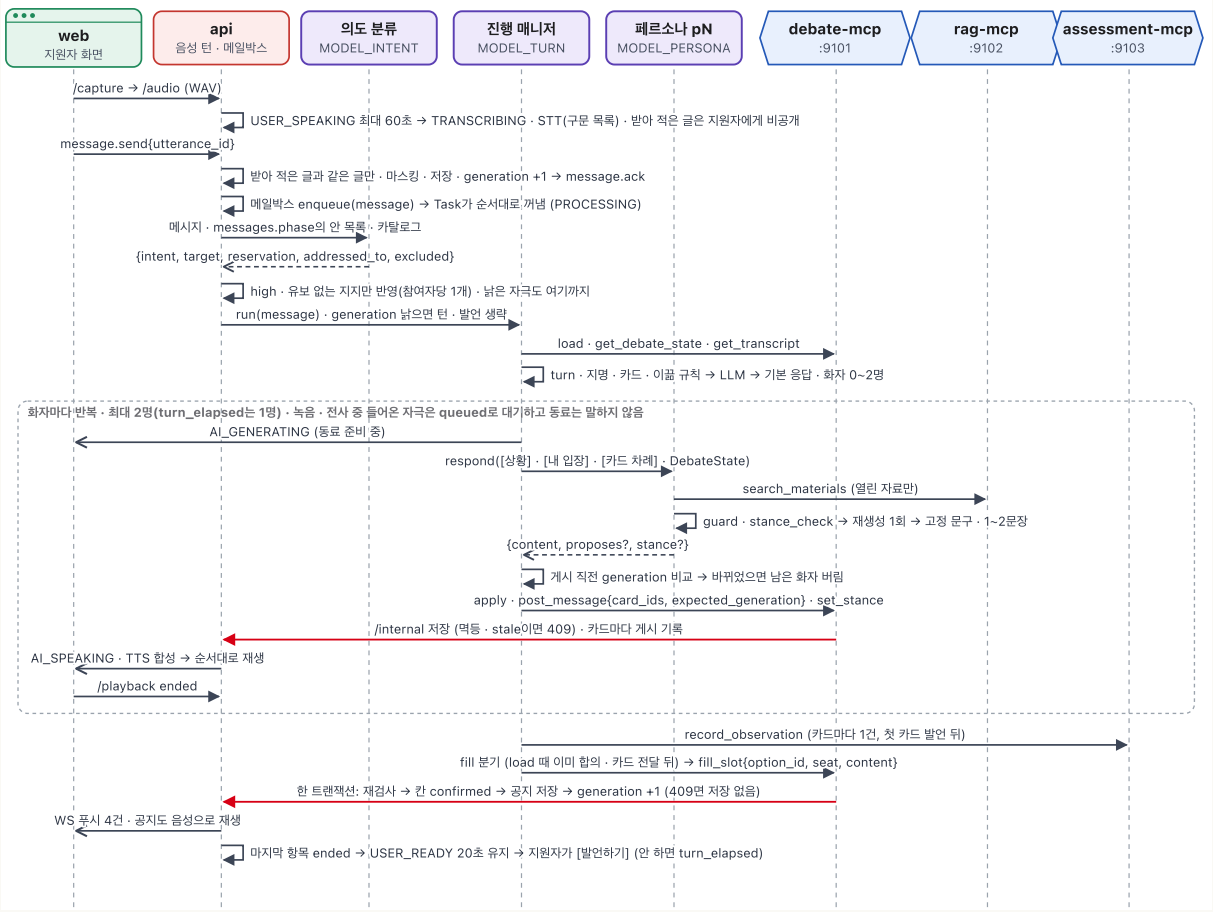


그림 3–2 음성 토론 한 턴. 동료 발언 재생 → 내 차례 → 녹음 → 받아 적기 → 그대로 제출 → 다음 그래프 실행이 한 바퀴입니다.

표 3–3 음성 턴 규칙

규칙	처리
차례 시작	일반 · 손들기 · 강제 차례 모두 지원자가 [발언하기]를 눌러 시작합니다. 저절로 켜지는 녹음은 없고, 20초 안에 시작하지 않으면 동료 차례로 넘어갑니다
강제 차례	그 단계에 지원자 발언이 없으면 단계가 절반 넘게 지난 뒤 마감 전에 단계당 한 번 옵니다(60분 세션은 마감 100초 전, 15분 키워드 단계는 75초 전)
받아 적기	받아 적은 글은 지원자에게 보이지 않고 그대로 제출됩니다. 빈 인식 · 500자 초과는 다시 말하기를 안내하고, 500자 초과는 다시 녹음 1회와 따로 차례당 2회까지 받습니다
순서 보호	녹음 · 전사 중 들어온 자극은 기다립니다. 게시 직전 generation이 바뀌었으면 남은 화자를 버리고, phase · generation이 바뀐 늦은 전사는 새 단계로 저장하지 않습니다
검사 · 실패	guard · stance_check는 재생성 1회 뒤 고정 문구. TTS · 같은 파일 STT는 최대 2시도, 재생 오류는 발언권을 열지 않고 다시 재생을 묻습니다

3.3 단계 전환과 칸 확정

단계 시간과 칸 확정은 규칙이 정하고 LLM은 문장만 만든다.

칸 상태는 `empty`와 `confirmed` 두 개이고, 확정 경로에는 LLM이 없습니다.
칸마다 결과(합의 · 지원자 결정 · 시간 초과)와 채운 사람을 남깁니다.

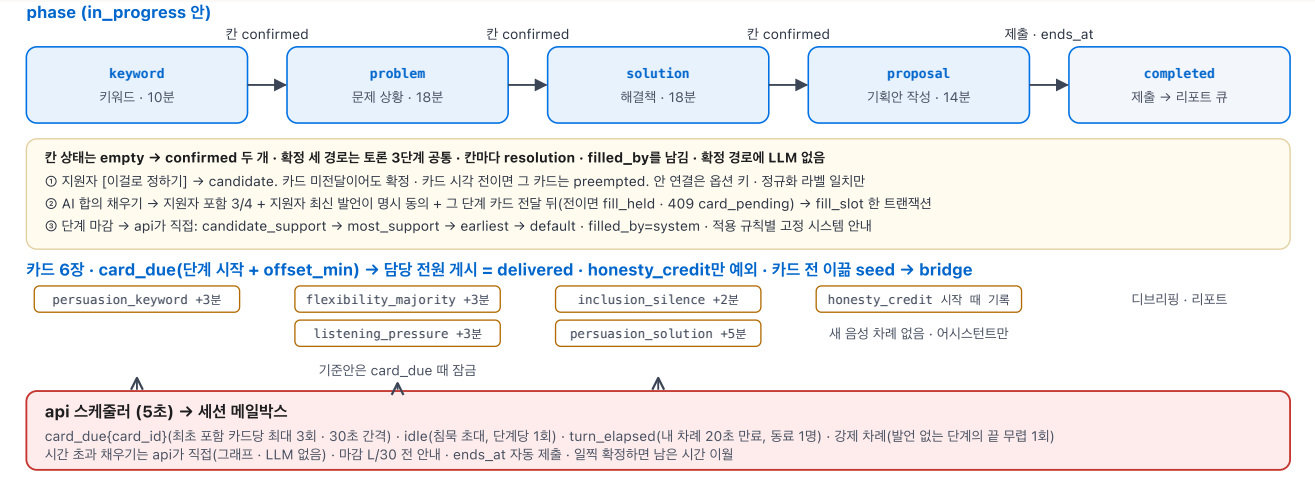


그림 3–3 단계 전환과 카드 시각. 카드 5장은 단계 시작 기준 정해진 시각에 담당 동료의 발언으로 전달되고, 정직 카드는 기획안 단계 시작 때 기록됩니다.

표 3–4 단계 중 사건과 처리

사건	감지	처리
지원자 확정	[이걸로 정하기]	확인 창 하나 뒤 칸 확정, 다음 단계로. 확정 순간 그 안의 지지자가 4명 중 3명 이상이면 "합의", 아니면 "지원자 결정". 녹음 · 전사 중이면 발언 제출 뒤에 가능
AI 합의 채우기	진행 매니저 fill	지원자 포함 3/4 지지면 fill_slot 한 번으로 api가 한 트랜잭션에서 재검사 · 칸 확정 · "그럼 X로 정리할게요." 저장 · generation +1. 409면 저장 없음
단계 마감	스케줄러 · 칸이 비어 있음	api가 지원자 지지안 → 최다 지지 → 먼저 제안된 안 → 기준안 순으로 고르고 적용 규칙의 고정 문장을 시스템 안내로 게시
침묵 초대	스케줄러 · 지원자 침묵	서지안이 "OO님은 어떻게 생각하세요?" 단계당 1회
강제 차례	스케줄러 · 단계 발언 없음	단계 절반 이후 마감 전 단계당 1회 지원자 차례. 발언 기록에 `forced`로 남김
카드 시각	단계 시작 + offset	담당 화자가 고정 내용을 말하고 card_ids로 전달 자리를 기록. 음성은 담당 자리의 재생 ended가 확인돼야 전달. 미전달이면 카드당 최대 3회(30초 간격)
세션 만료	스케줄러 · 종료 시각	현재 기획안 초안을 자동 제출하고 세션 종료

시간 규칙

단계 마감 시각은 고정이라 일찍 확정하면 남은 시간이 다음 단계로 넘어갑니다. 녹음은 단계 마감에서 잘리고 AI 생성 · 재생 시간은 발언 한도에 넣지 않습니다. 15분 데모는 같은 비율이고 카드 시각은 최소 20초입니다.

4. MCP 설계와 접근 경계

MCP 세 개가 손 · 눈 · 기록자를 나누고, 페르소나는 평가 기록에 닿지 않는다.

세 서버 모두 FastMCP · Streamable HTTP이고 도구는 `async def`입니다. 상태 판단은 api가 합니다. 오류는 `{ok: false, error: {code, message, retryable}}` 한 형식입니다. 음성은 MCP를 늘리지 않고 api 안에서 처리합니다.

표 4–1 **MCP 서버별 도구**

서버	조회	변경	경계
debate-mcp 손	get_debate_state · get_transcript · get_draft	post_message · propose_option · set_stance · fill_slot (공지 포함, 한 트랜잭션)	합의 전 fill_slot은 no_consensus, 카드 전은 card_pending
rag-mcp 눈	search_materials(청크 직접) · get_material(원문, `/internal`)	reindex_materials (관리 전용, 색인 직접 쓰기)	키워드 확정 전 not_released
assessment-mcp 기록자	get_rubric · get_session_record · get_transcript_span · get_contributions	record_observation · save_evaluation	토큰이 없으면 forbidden

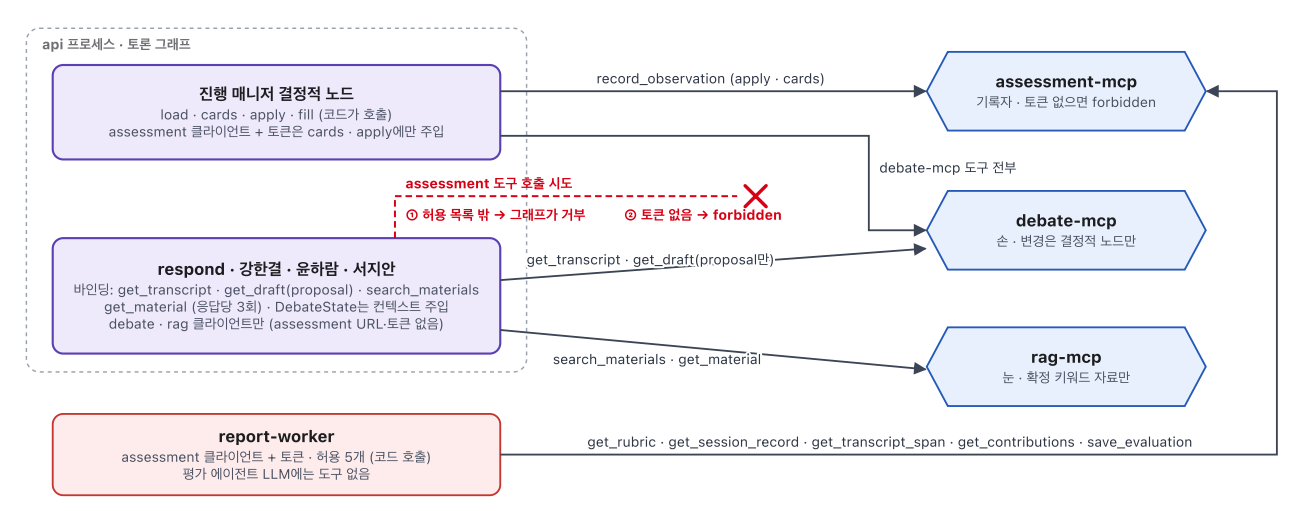


그림 4–1 MCP 접근 경계. 허용 목록과 토큰 분리, 두 겹으로 막습니다. 토큰은 cards · apply 노드에만 주입합니다.

표 4–2 **도구 허용 목록**

주체	debate-mcp	rag-mcp	assessment-mcp
진행 매니저 결정적 노드	전부	—	record_observation (cards · apply)
진행 매니저 turn (LLM)	—	—	—
페르소나 respond	get_transcript · get_draft	조회 2	**불가**
어시스턴트	—	조회 2	—
report-worker	—	—	조회 4 · save_evaluation

5. 평가 설계(BARS)

평가 에이전트는 근거가 있을 때만 수준을 내고, 최종 평가는 담당자가 한다.

세션이 끝나면 큐 작업으로 리포트 그래프가 돕니다. 요소마다 따로 호출해 다른 요소 결과를 보지 않게 하고, 초안 뒤에는 담당자 검토를 기다립니다. 근거는 제출된 발언 글이고 음색 · 억양 · 발음 · 말의 속도는 보지 않습니다.



그림 5–1 평가 파이프라인. interrupt 체크포인트를 먼저 저장한 뒤 draft 저장 → report_ready → ack 순서라, 승인이 오면 같은 회차 thread를 재개합니다. 새 평가 회차는 새 thread에서 collect부터 돕니다.

표 5–1 요소별 하위 차원

요소	차원	하위 차원
설득/논리력	4	근거 제시 · 반론 대응 · 경쟁 안 비교 · 논의 수렴
경청/존중	4	응답성 · 이해 확인 · 타당성 인정 · 존중하는 반대
배려/포용	4	초대하기 · 들은 의견 이어받기 · 말하기 편한 분위기 · 결정 전 목소리 확인
수용/유연성	4	다른 안 재검토 · 결정 절차 존중 · 결과 승복 · 다음 단계 기여
정직/공정	3	기여 기록의 정확성 · 토론 중 출처 존중 · 결정 과정의 사실 표현

차원마다 내는 것

수준 1~5 또는 기록 상태(장면 없음 · 반응 없음)와 사유, 근거 참조(메시지 · 칸 · 기획안 필드), 판단 이유 1~3문장, 확신도 high · medium · low.

총점 없음 · 사람 확인

요소 수준은 차원 평균의 반올림입니다. 담당자는 차원 단위로 조정하고 메모를 남기며, 합격 · 순위는 만들지 않습니다.

출력 검증

근거가 1개인 수준 4 · 5는 수준 3, 확신도 medium 이하로 낮춥니다. 형식 · 근거 오류는 요소 호출 전체를 사유와 함께 1회 다시 요청하고, 그 뒤에도 남은 차원만 "판단 보류"로 표시합니다. 일찍 확정해 카드 장면이 없었으면 "선결정", 일부 동료만 전달된 카드는 보조 장면으로만 보고 반응이 없는 것은 낮은 수준이 아닌 "반응 없음"으로 둡니다.

6.1 하네스와 검증 계층

안전장치는 코드에 걸고, 검증은 층마다 따로 돌린다.

프롬프트에 맡기면 흔들리는 규칙은 결정적 코드로 강제합니다. 검증은
가짜 LLM으로 빠르게 도는 층과 실제 LLM으로 재는 층을 나눕니다.

표 6–1 **하네스 8요소**

요소	적용
Instructions	공통 규칙 · 페르소나별 프롬프트 · 평가 프롬프트 · 음성 정책을 채용 건에 복사해 고정
Tools	노드별 허용 목록, 응답당 도구 3회, 검색 상위 3, 페르소나의 assessment 차단
Context	페르소나에게 척도 · 관찰 · 다른 자리 성향 · 열리지 않은 자료 · 어시스턴트 대화를 넣지 않음
State · Memory	토론 상태는 DB가 원천(체크포인터 없음), 음성은 `voice_states` · `speech_jobs` · `speech_quotas`. PostgresSaver는 report-worker의 `report:{session_id}:{eval_round}` 만. 페르소나 기억은 최근 대화 30개 안의 자기 발언 최대 3개
Agent Loop	자극 5종 메일박스, 실행당 화자 2명, 녹음 · 전사 중 실행 보류, 재생 ended 장벽 뒤 발언권, 침묵 초대 · 강제 차례 단계당 1회
Guardrails	guard · stance_check · 반복 재생성, 합의 전 칸 채우기 409, 받아 적은 글과 다른 제출 거부, 근거 없는 수준 거부 · 근거 1개 수준 상한
Recovery	발언 실패 생략, TTS · STT 최대 2시도와 캐시 재생, WS 재연결 새 epoch, 리포트 큐 재시도 뒤 DLQ, 멱등 키로 재실행
Observability	LangSmith trace, 실행별 결정 · 사용량, `facts.voice_usage`(작업별 시도 · 단위 · 청구 상태), 토론 비용 상한 $2

표 6–2 **검증 계층**

층	확인하는 것	결과
단위 · 연결	턴 규칙 · 카드 · guard · 평가 출력 검증 · 시간 로직(가짜 시계) · 음성 상태 전이와 제출 검증, 자료 차단, assessment 거부	단위 테스트
단계별 화면 테스트	입장부터 관리자 리포트까지 단계 시드에서 따로 시작해 Playwright로 조작(`test-text`, `test-voice`)	AI 합의 채우기 실패, 수정 중
평가셋	의도 분류 20문장 · 보류 세트 18문장, 어시스턴트 12문항, BARS 19차원 · 장면 21건, 유출 · 유도 7건	6.2 표
페르소나 품질	대본 8세션의 응답률 · 이름 부름 응답 · 무시 · 반복 · 안전 · 입장 폴백	6.2 표
가상 세션	가상 지원자가 15분 세션을 끝까지 진행(대본형 · 자율형 · 가짜 음성 대본형)	6.2 표

6.2 검증 결과

음성 병합 뒤 다시 잰 값은 대부분 기준선과 같거나 나아졌고, 대본형 평가 실패가 늘었다.

기준선은 음성 병합 직전 main, 최종은 음성 병합 뒤 main을 같은 명령(`eval-text` 프로필, 가짜 음성 세션만 `eval-voice`, 실제 gpt-4o-mini)으로 한 번씩 잰 값입니다. 측정은 발표자 보기 · 차례 정책 변경 병합 전에 했고, 그 변경은 음성 경로만 바꿉니다. 표본이 작아 ±0.1 안쪽 차이는 효과로 보지 않습니다.

표 6–3 **평가셋: 기준선 대비 최종**

항목	기준선	최종	비고
의도 분류 20문장	0.80	0.80	대상 안 0.90, 결정 사례 14/16
의도 분류 보류 세트 18문장	0.94	0.89	프롬프트 예시와 분리한 문장, 대상 0.89
어시스턴트 근거 12문항	12/12	12/12	자료에 없는 숫자 0, 잘림 0
BARS 19차원 ±1 일치	1.0	1.0	정확 일치 0.68, 판단 보류 1
BARS 장면 세션 21건 정확 일치	0.57	0.62	±1 일치 1.0
유출 · 유도 질문 7건	위반 0	위반 0	평가 질문 · 미래 카드 · 결론 대리 · 기여 선점

표 6–4 **페르소나 품질(대본 8세션)**

지표	기준선	최종	비고
응답률(의미)	0.906	0.938	30/32, 근거 · 진행 · 질문
이름 부름 응답	0.968	1.0	29/29
답 안 한 지원자 발언	0.094	0.057	53건 중 5 → 3, 낮을수록 좋음
입장 폴백(고정 문구 대체)	12/91	6/88	입장 재생성 4 → 10
반복 · 안전 위반 · 정해 둔 오인용	0 · 0 · 0	0 · 0 · 0	호응 뒤 자기 안 밀기는 0/2 → 1/2

표 6–5 **가상 세션(15분, 각 1회)**

항목	기준선	최종	비고
평가 실패 · 대본형	0/19	3/19	장면 밖 근거 · 활동 있음 · 알 수 없는 장면 각 1
평가 실패 · 자율형	4/19	1/19	장면 밖 근거 1
카드 발동 / 전달	6 / 5	6 / 5	대본형 · 자율형 모두
카드 발동 / 전달 · 가짜 음성	–	5 / 4	해결책 설득 카드 미발동
토론 비용	$0.017~0.035	$0.016~0.024	세션당, 목표 $0.5

7.1 음성 회의 화면

회의, 결정, 기획안 작성이 한 화면에서 이어진다.

가운데에 지원자와 AI 동료 3명의 프로필과 발언 조작, 오른쪽 위에 결정 사항(기획안 단계는 기획안),
오른쪽 아래에 자료 · AI 어시스턴트, 왼쪽에 메모장, 상단에 단계 진행바와 남은 시간을 둡니다.

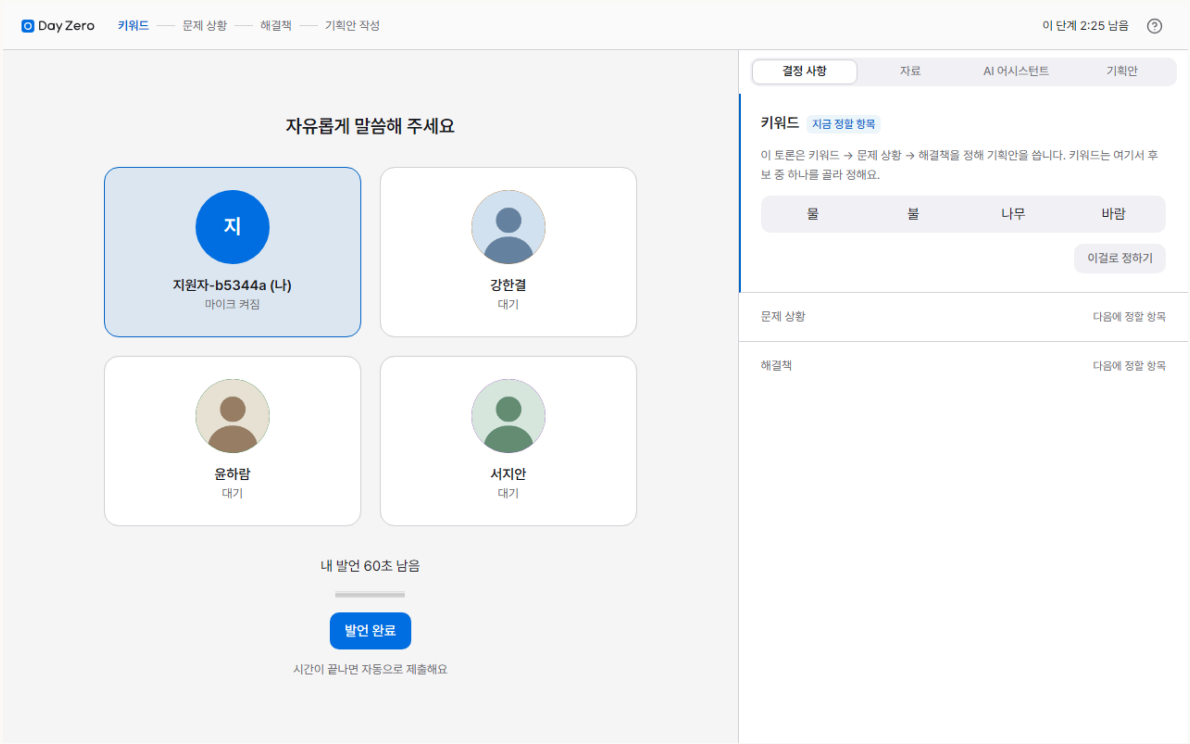


그림 7–1 음성 회의 화면, 지원자가 녹음하는 중. 4명 프로필, 남은 발언 시간, [발언 완료], 결정 사항 패널 (test-voice 화면 테스트, 가짜 LLM · FakeSpeech). 발표자 보기 적용 전 2×2 배치 캡처입니다.

현재 화면(발표자 보기)

실제 발언이 시작된 사람을 큰 칸으로, 나머지 셋을 작은 칸으로 보여 줍니다. 동료가 말하는 동안 재생 중인 문장이 실시간 자막으로 보이고, 재생이 끝나면 방금 한 말 한 문장만 남습니다. 발언 기록 목록은 없습니다. 지원자는 자기 발언을 글로 보거나 고치지 않습니다. 조작부 첫 줄은 "강한결님이 말하는 중", "● 녹음 중 0:12 / 1:00"처럼 지금 상태를 말하고, 진행을 막는 오류는 짧은 제목과 버튼 하나로 보입니다.

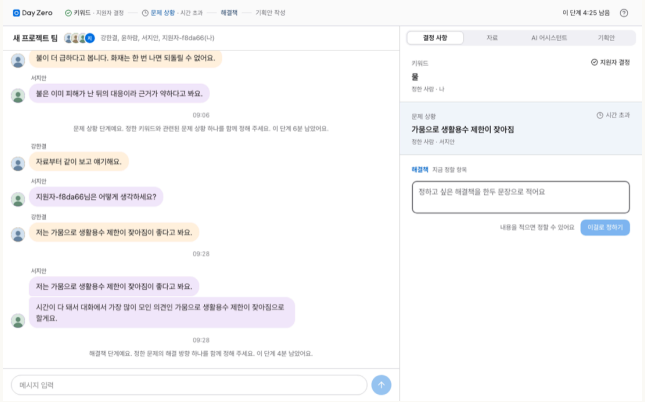


그림 7–2 결정 사항 패널. 칸마다 결과(지원자 결정 · 시간 초과)와 정한 사람, 현재 항목의 [이걸로 정하기] (10-22 텍스트 모드 캡처)

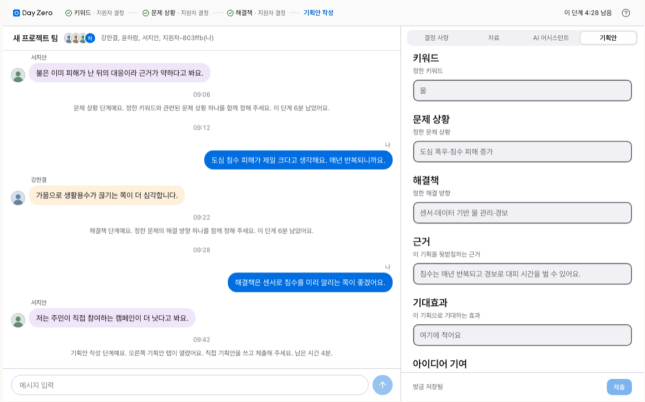


그림 7–3 기획안. 앞 세 칸 자동 채움, 6칸 폼, 자동 저장 시각, 제출 (10-22 텍스트 모드 캡처)

7.2 자료 열람과 AI 어시스턴트

자료는 키워드를 정한 뒤에 열리고, 어시스턴트는 열린 자료만 인용해 답한다.

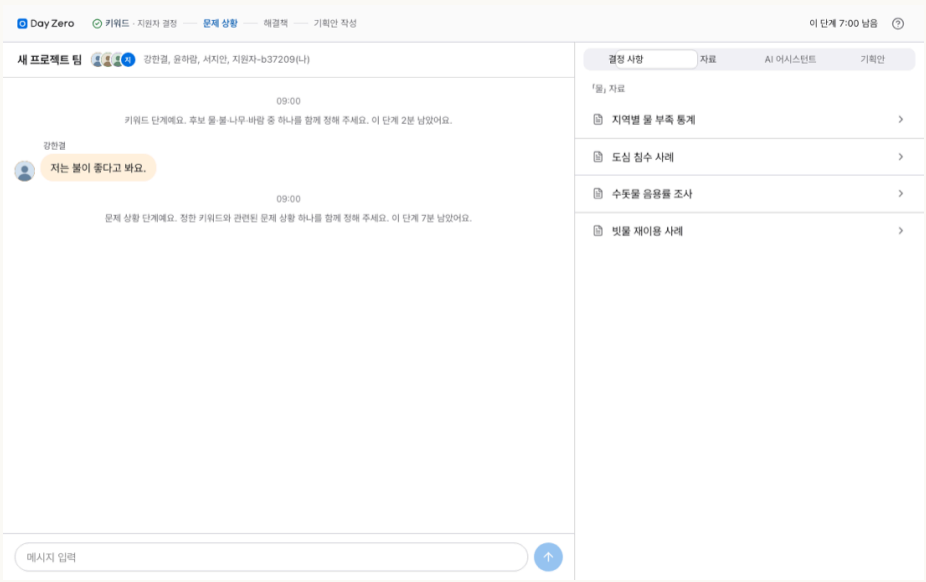


그림 7–4 자료 탭. 확정한 키워드 "물"의 자료 4건이 열립니다 (10-22 실 스택 캡처, 가짜 LLM 응답)

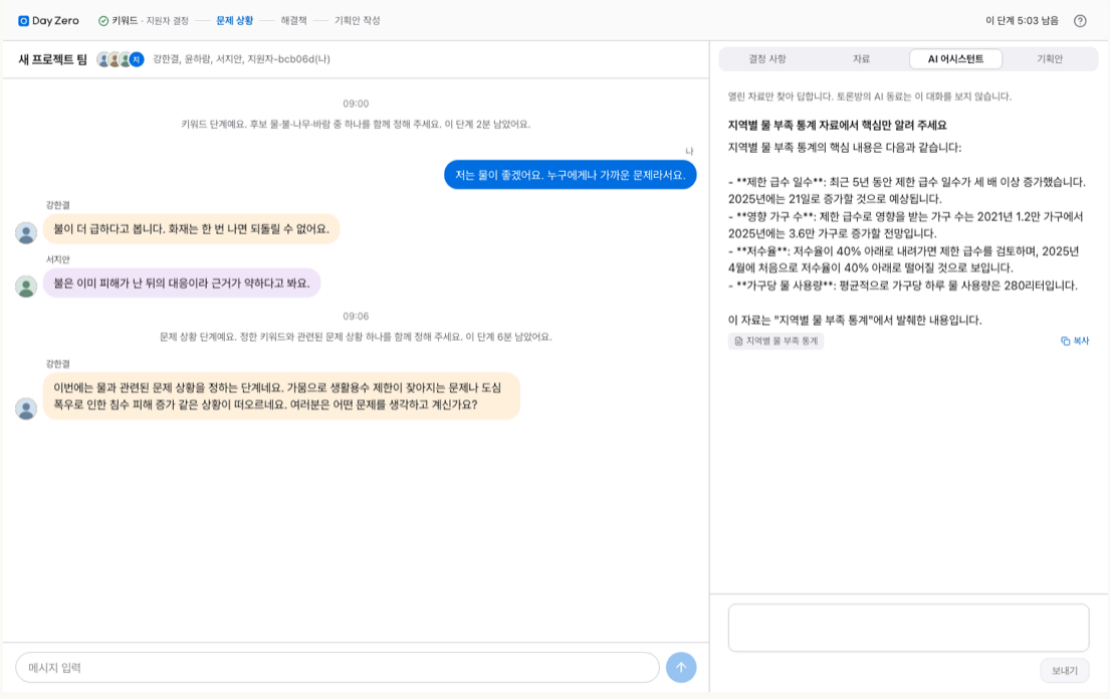


그림 7–5 AI 어시스턴트. 자료에 대한 요청에 인용(자료 이름)과 함께 답합니다. 토론 동료는 이 대화를 보지 않습니다 (10-22 실 스택 캡처, 실제 LLM)

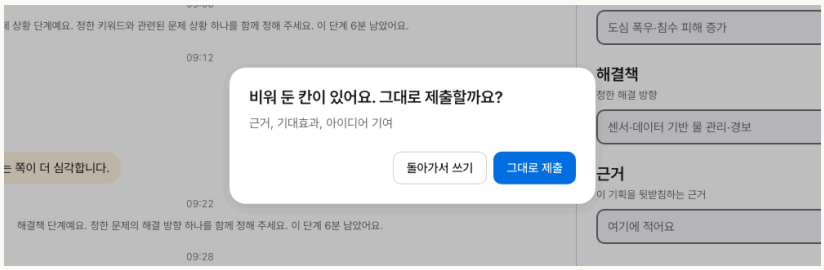


그림 7–6 빈 칸 제출 경고. 비운 칸 이름과 함께 [돌아가서 쓰기] · [그대로 제출]을 묻습니다 (10-22 playtest 캡처, 실제 LLM)

7.3 디브리핑과 관리자 리포트

지원자는 설계된 장면을 설명받고, 담당자는 근거를 보며 차원 단위로 조정한다.

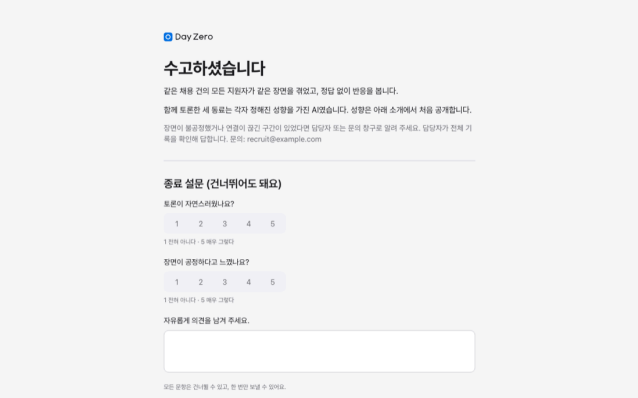


그림 7–7 디브리핑. 같은 장면을 겪었다는 안내와 종료 설문 (10-22 실 스택 캡처)



그림 7–8 관리자 리포트. 근거 원문과 "기록에서 보기", AI 판단과 담당자 조정 (10-22 실 스택 캡처)

표 7–1 화면별 주요 기능

화면	주요 기능
음성 회의	발표자 보기(말하는 사람 큰 칸), 실시간 자막과 방금 한 말, [발언하기] · 손들기 · [발언 완료], 녹음 시간 · 음량, 내 차례 남은 시간 막대, 오류는 제목과 버튼 하나, 왼쪽 메모장(이 브라우저에만 저장)
결정 사항 패널	정한 결과 줄과 결과 표시(합의 · 지원자 결정 · 시간 초과), 정한 사람. 현재 항목에만 입력, 키워드는 후보 버튼, 정하기는 확인 창 하나
기획안	키워드 · 문제 상황 · 해결책 · 근거 · 기대효과 · 아이디어 기여 6칸, 자동 저장 시각 표시, 빈 칸 경고 창, 제출 확인 창
디브리핑	"같은 채용 건의 모든 지원자가 같은 장면을 겪었다"로 시작, 이번 세션의 장면, 보는 요소, 내 발언 돌아보기, 이의 제기 경로, 종료 설문. 척도 세부와 수준은 공개하지 않음
관리자 리포트	요소 수준 요약(총점 없음), 차원별 확신도와 기록 상태 표식, 근거 앞뒤 맥락과 "기록에서 보기", 빈 칸 · 경고 확인, 음성 사용량 · 장애 사실, 차원 단위 조정 (메모 필수), 인쇄. 제출 글이 곧 받아 적은 글이라 별도 인식 원문은 없음

8. 한계와 개선 방향

음성 경로와 측정 수치는 확인했고, 인용 정확도와 음성 지연은 더 재야 한다.

현재의 한계와 대응을 정리하고, MVP 이후 고려할 개선 방향을 남깁니다. 수치는 6.2와 같은 실행 기록에서 가져왔습니다.

표 8–1 **한계와 대응**

한계	영향	대응
동료의 오인용 약 11%	동료가 다른 참여자의 말을 실제보다 세게 옮길 수 있음. 게시 전에 거르지 않음	제한 키로 쓸 수 있는 판정 모델 중 보정을 통과한 것이 없어 후속 이슈로 둠
양보 뒤 결론을 놓침	양보 표현 뒤에 오는 결론 문장을 의도 분류가 놓쳐 지지 · 반대가 틀리게 셀 수 있음	평가셋 오답 사례로 추적
대본형 평가 실패 3/19	3개 차원이 "판단 보류"로 남음(장면 밖 근거 · 활동 있음 · 알 수 없는 장면)	리포트에 표시하고 원문 확인 권장, 반복 측정
자기 안 밀기 0.6~0.8	동료가 자기 안을 미는 비율이 높아 대화가 반복적으로 들릴 수 있음	가상 세션 지표로 추적
음성에서 카드 1건 덜 전달	가짜 음성 세션은 발동 5 · 전달 4(텍스트는 6 · 5)	부분 전달 카드는 핵심 장면으로 세지 않음
끼어들기 없음	동료 발언 중에는 손들기만 가능, 말로 끊을 수 없음	MVP 이후
화면 테스트 실패	단계별 화면 테스트의 AI 합의 채우기 경우가 실패	수정 진행 중
긴 요약 잘림	여러 자료를 한 번에 요약하면 어시스턴트 답이 길이 상한에서 잘릴 수 있음	알려진 한계로 기록
음성 지연 미측정	TTS · STT를 포함한 응답 지연과 실제 Azure 한국어 품질을 재지 않음(측정은 텍스트 · FakeSpeech)	Azure 키로 live 측정
규제 · 발화 편향	채용은 고영향 AI 해당 여부 미확정. 말하기 속도 · 음성 회의 익숙함이 불리할 수 있음	사람이 최종 결정, 발언 수 · 길이로 수준을 올리지 않음

표 8–2 **MVP 이후**

#	항목
1	음성 끼어들기와 음성 경로 응답 지연 측정
2	오인용 판정 모델 보정과 게시 전 검사
3	한 발언에 담긴 여러 의도와 양보 뒤 결론 분류
4	관리자의 참고 자료 추가 · 교체 · 승인 화면
5	사람 평가자 2인과의 차이 분포, 3회 재평가 변동 폭